

# Kalman Filter

Kalman Filter berfungsi untuk melakukan prediksi dan estimasi pada *state* (keadaan) suatu sistem.

Kalman filter membutuhkan 2 model, yaitu state model dan observation model

## 1. State Model

State model adalah persamaan / model yang merepresentasikan perubahan *state* pada sistem w.r.t waktu.

## 2. Observation Model

Observation model adalah persamaan / model yang merepresentasikan data yang diukur biasanya dengan sensor yang memberikan data eksternal robot dihubungkan dengan keadaan sistem.

## Multivariate Kalman Filter

State pada sistem

$$\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}$$


Multivariate Kalman Filter memberikan output berupa **multivariate random variabel** dan **covariance matrix** merupakan matriks persegi sebesar jumlah state ketidakpastian.

Covariance matrix pada **Kalman Filter** meliputi :

- $P_{n,n}$  : covariance matriks pada estimasi
- $P_{n+1,n}$  : covariance matriks pada prediksi
- $R_n$  : covariance matriks yang menggambarkan ketidakpastian pengukuran
- $Q$  : covariance matriks untuk proses noise

## Covariance

Covariance mengukur seberapa korelasi antara 2 atau lebih variabel random



Covariance antara populasi  $X$  dan populasi  $Y$  dengan banyak data  $N$ :

$$COV(X, Y) = \frac{1}{N} \sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)$$

Jika menggunakan sample:

$$COV(X, Y) = \frac{1}{N-1} \sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)$$

## Covariance Matrix

Covariance matrix adalah matriks persegi yang merepresentasikan covariance antar setiap element pada setiap state.

$$\Sigma = \begin{bmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{yx} & \sigma_{yy} \end{bmatrix} = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{yx} & \sigma_y^2 \end{bmatrix} = \begin{bmatrix} VAR(x) & COV(x, y) \\ COV(y, x) & VAR(y) \end{bmatrix}$$

Jika  $x$  dan  $y$  tidak berkorelasi maka bagian dari matriks  $\Sigma$  yang bukan diagonal bernilai 0

Jika memiliki state  $x$  dengan dimensi  $1 \times k$ ,

$$COV(x) = E((x - \mu_x)(x - \mu_x)^T)$$

Proof :

$$\begin{aligned} COV(x) &= E \left( \begin{bmatrix} (x_1 - \mu_{x_1})^2 & (x_1 - \mu_{x_1})(x_2 - \mu_{x_2}) & \cdots & (x_1 - \mu_{x_1})(x_k - \mu_{x_k}) \\ (x_2 - \mu_{x_2})(x_1 - \mu_{x_1}) & (x_2 - \mu_{x_2})^2 & \cdots & (x_2 - \mu_{x_2})(x_k - \mu_{x_k}) \\ \vdots & \vdots & \ddots & \vdots \\ (x_k - \mu_{x_k})(x_1 - \mu_{x_1}) & (x_k - \mu_{x_k})(x_2 - \mu_{x_2}) & \cdots & (x_k - \mu_{x_k})^2 \end{bmatrix} \right) \\ &= E \left( \begin{bmatrix} (x_1 - \mu_{x_1}) \\ (x_2 - \mu_{x_2}) \\ \vdots \\ (x_k - \mu_{x_k}) \end{bmatrix} \begin{bmatrix} (x_1 - \mu_{x_1}) & (x_2 - \mu_{x_2}) & \cdots & (x_k - \mu_{x_k}) \end{bmatrix} \right) \\ &= E((x_{1:k} - \mu_{x_{1:k}})(x_{1:k} - \mu_{x_{1:k}})^T) \end{aligned}$$

Note :

$E(v)$  adalah ekspektasi, rata-rata dari variabel random

## Covariance Matrix Properties

- $\Sigma_{ii} = \sigma_{ii}^2$
- $tr(\Sigma) = \sum_{i=1}^n \Sigma_{ii} \geq 0$
- $\Sigma = \Sigma^T$

## Multivariate Gaussian Distribution

$$p(x|\mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp \left( -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right)$$

## State Equation

Befungsi untuk melakukan prediksi berdasarkan estimasi yang sudah ada.

$$\hat{x}_{n+1,n} = F\hat{x}_{n,n} + G\hat{u}_{n,n} + w_n$$

$\hat{x}_{n+1,n}$  : prediksi state pada  $n + 1$

$\hat{x}_{n,n}$  : prediksi state pada  $n$

$u_n$  : variabel kontrol *input* terukur ke dalam sistem

$w_n$  : noise, *input* tidak terukur ke dalam sistem (disebut proses noise)

$F$  : matrix transisi

$G$  : matrix kontrol (mapping efek  $u_n$  ke variabel *state*)

Persamaan state dapat diperoleh dengan *State Space Equations* dengan menganalisa dynamic dari sistem.

## Covariance Equation

Mengukur ketidakpastian dari prediksi *State Equation*

$$P_{n+1,n} = FP_{n,n}F^T + Q$$

Proof :

dengan  $COV(x) = E((x_{1:k} - \mu_{x_{1:k}})(x_{1:k} - \mu_{x_{1:k}})^T)$ , maka

$P_{n,n} = E((\hat{x}_{n,n} - \mu_{\hat{x}_{n,n}})(\hat{x}_{n,n} - \mu_{\hat{x}_{n,n}})^T)$  , dengan menggunakan *state equation* dapat diperoleh  $P_{n+1,n}$

$$\begin{aligned} P_{n+1,n} &= E((\hat{x}_{n+1,n} - \mu_{\hat{x}_{n+1,n}})(\hat{x}_{n+1,n} - \mu_{\hat{x}_{n+1,n}})^T) \\ &= E((F\hat{x}_{n,n} + G\hat{u}_{n,n} - F\hat{\mu}_{x_{n,n}} + G\hat{u}_{n,n})(F\hat{x}_{n,n} + G\hat{u}_{n,n} - F\hat{\mu}_{x_{n,n}} + G\hat{u}_{n,n})^T) \\ &= E(F(\hat{x}_{n,n} - \mu_{x_{n,n}})(F(\hat{x}_{n,n} - \mu_{x_{n,n}}))^T) \\ &= E(F(\hat{x}_{n,n} - \mu_{x_{n,n}})(\hat{x}_{n,n} - \mu_{x_{n,n}})^T F^T) \\ &= FE(\hat{x}_{n,n} - \mu_{x_{n,n}})(\hat{x}_{n,n} - \mu_{x_{n,n}})^T F^T \end{aligned}$$

sehingga,

$$P_{n+1,n} = FP_{n,n}F^T$$

## Observation Model

$$z_n = Hx_n + v_n$$

$z_n$  : vektor observasi

$H$  : matriks observasi

$x_n$  : state sebenarnya

$v_n$  : random noise (disebut noise observasi)

Contoh pada kasus sensor jarak ultrasonik, state dari sistem adalah jarak  $x_n$ , output dari sensor merupakan ToF yang terukur  $z_n$ , maka *observation model*-nya :

$$z_n = \left[\frac{2}{c}\right]x_n + v_n$$

dengan  $c$  merupakan kecepatan suara

### Observation Uncertainty

$$R_n = E(v_n v_n^T)$$

$R_n$  : covariance matrix untuk observasi

$v_n$  : kesalahan observasi

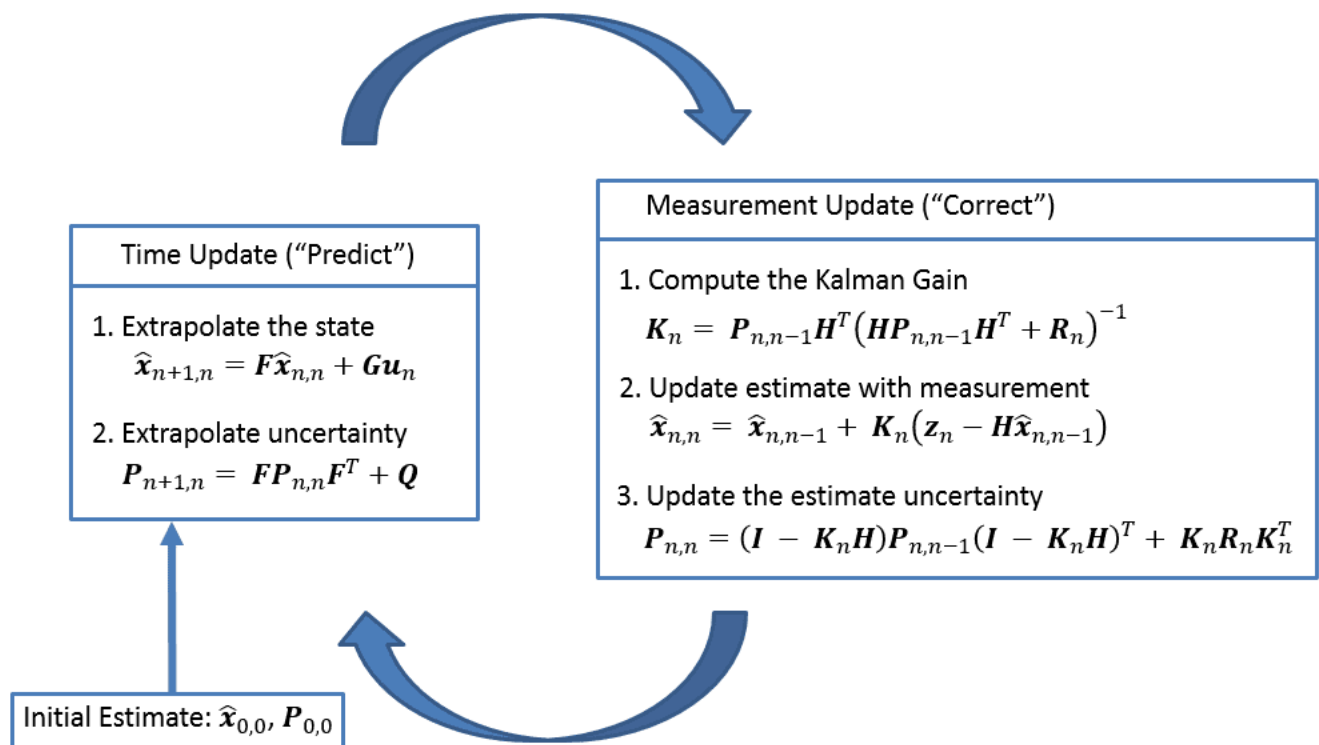
### Process Uncertainty

$$Q_n = E(w_n w_n^T)$$

$Q_n$  : covariance matrix untuk proses noise

$w_n$  : proses noise

### Summary



### Kalman Gain

Kalman Gain merupakan bobot bagi *measurement model*, dengan kata lain *Kalman Gain* menentukan seberapa besar pengaruh *measurement model* terhadap estimasi *state*.

$$KG = \frac{error_{estimate}}{error_{estimate} + error_{measurement}}$$

- $error_{estimate} > error_{measurement} : KG \rightarrow 1$
- $error_{estimate} < error_{measurement} : KG \rightarrow 0$

$$estimate_t = estimate_{t-1} + KG(measurement_t - estimate_{t-1})$$

## Error on Estimation

$$E_{estimate_t} = [1 - KG]E_{estimate_{t-1}}$$

- $KG \rightarrow 1$ , maka error pada estimasinya besar, sehingga persamaan diatas akan menghasilkan  $E_{estimate}$  yang kecil
- $KG \rightarrow 0$ , maka error pada estimasinya kecil, sehingga persamaan diatas akan mempertahankan error estimasi dari waktu  $t - 1$
- $E_{estimate_t} < E_{estimate_{t-1}}$

Note :

Saat varians pada estimasi mengecil, maka mendekati nilai sebenarnya

## References :

- [kalmanfilter.com](http://kalmanfilter.com)
- [Michel van Biezen - Kalman Filter Playlist](#)