

# Pose Graph SLAM

$$e_{ij}(x) = z_{ij} - \hat{z}(x_i, x_j)$$

$e_{ij}(x)$  adalah fungsi error,  $z$  berdasarkan measurement model,  $\hat{z}$  berdasarkan model matematika, dan  $x$  merupakan state. Diasumsikan error pada data sensor memiliki distribusi Gaussian,

$$p(x) = \frac{1}{\sqrt{2\pi^n |\Sigma|}} \exp \left( -\frac{1}{2} (x - \mu)^T \Omega (x - \mu) \right) \sim \mathcal{N}(\mu, \Sigma)$$

$\Omega = \Sigma^{-1}$  merupakan information matrix, sehingga error merupakan multivariate normal distribution dengan  $\mu = \hat{z}$  dan varians  $\Sigma$ . Dengan menerapkan log-likelihood pada  $p(x)$ , state optimal  $x^*$  dapat diperoleh dengan Maximum Likelihood Estimation,  $x$  optimal apabila  $\ln(p(x))$  mencapai nilai maksimum.

$$x^* = \operatorname{argmax}_x p(x) = \operatorname{argmin}_x e_{ij}^T \Omega_{ij} e_{ij}$$

Dikarenakan adanya kumulatif error pada trajectory, yang merupakan error bukan hanya pada 1 pose melainkan terdapat kemungkinan error terjadi lebih dari 1 pose. Sehingga fungsi error merupakan jumlah dari setiap error pada setiap pose,

$$F(x) = e_{ij}^T \Omega_{ij} e_{ij}$$
$$x^* = \operatorname{argmin}_x \sum_{i,j} F(x_{ij})$$

Persamaan tersebut tidak memiliki solusi pasti dikarenakan terdapat matriks rotasi yang mengindikasikan persamaan non-linear. Permasalahan dapat diselesaikan dengan menggunakan optimisasi dan dilinearkan menggunakan Taylor-Expansion.

$$F_{ij}(x + \Delta x) = e_{ij}(x + \Delta x)^T \Omega_{ij} e_{ij}(x + \Delta x)$$

Dengan menggunakan **First-Order Taylor Expansion**,

$$e_{ij}(x + \Delta x) = e_{ij} + J_{ij} \Delta x$$

Substitusikan ke  $F_{ij}(x + \Delta x)$ ,

$$\begin{aligned} F_{ij}(x + \Delta x) &= (e_{ij} + J_{ij} \Delta x)^T \Omega_{ij} (e_{ij} + J_{ij} \Delta x) \\ &= (e_{ij}^T + (J_{ij} \Delta x)^T) + (\Omega_{ij} e_{ij} + \Omega_{ij} J_{ij} \Delta x) \\ &= (e_{ij}^T + \Delta x^T J_{ij}^T) (\Omega_{ij} e_{ij} + \Omega_{ij} J_{ij} \Delta x) \\ &= e_{ij}^T \Omega_{ij} e_{ij} + e_{ij}^T \Omega_{ij} J_{ij} \Delta x + \Delta x^T J_{ij}^T \Omega_{ij} e_{ij} + \Delta x^T J_{ij}^T \Omega_{ij} J_{ij} \Delta x \\ &= e_{ij}^T \Omega_{ij} e_{ij} + e_{ij}^T \Omega_{ij} J_{ij} \Delta x + (\Delta x^T J_{ij}^T \Omega_{ij} e_{ij})^T + \Delta x^T J_{ij}^T \Omega_{ij} J_{ij} \Delta x \\ &= e_{ij}^T \Omega_{ij} e_{ij} + e_{ij}^T \Omega_{ij} J_{ij} \Delta x + e_{ij}^T \Omega_{ij}^T J_{ij} \Delta x + \Delta x^T J_{ij}^T \Omega_{ij} J_{ij} \Delta x \end{aligned}$$

Dikarenakan  $\Omega_{ij}$  adalah metriks simetrik, maka  $\Omega_{ij} = \Omega_{ij}^T$

$$F_{ij}(x + \Delta x) = \underbrace{e_{ij}^T \Omega_{ij} e_{ij}}_c + \underbrace{2e_{ij}^T \Omega_{ij} J_{ij} \Delta x}_b + \Delta x^T \underbrace{J_{ij}^T \Omega_{ij} J_{ij}}_H \Delta x$$

Dapat diperoleh turunan pertama dari  $F_{ij}(x + \Delta x)$ ,

$$\frac{\partial F_{ij}(x + \Delta x)}{\partial \Delta x} \approx 2b + 2H\Delta x = 0$$

$$\Delta x = -H^{-1}b$$

$$x \leftarrow x + \Delta x$$

$\hat{z}_{ij}$  dihitung dengan *inverse pose composition*,

$$T \in SE(n)$$

$$R \in SO(n)$$

$$T_i^{-1} = \begin{bmatrix} R_i^T & -R_i^T t_i \\ 0 & 1 \end{bmatrix}$$

$$T_j = \begin{bmatrix} R_j & t_j \\ 0 & 1 \end{bmatrix}$$

$$\hat{z}_{ij} = T_i^{-1} \cdot T_j$$

$$\hat{z}_{ij} = \begin{bmatrix} R_i^T R_j & R_i^T (t_j - t_i) \\ 0 & 1 \end{bmatrix} \triangleq \begin{bmatrix} R_i^T (t_j - t_i) \\ \theta_j - \theta_i \end{bmatrix} \rightarrow \text{vector space}$$

$$\text{vector space} = \begin{bmatrix} \Delta t \\ \Delta \theta \end{bmatrix}$$

Nilai  $e_{ij}$  diperoleh dengan cara yang sama seperti  $\hat{z}_{ij}$ , Sehingga  $e_{ij} = z_{ij}^{-1} T_i^{-1} T_j$

$$e_{ij} = \begin{bmatrix} R_{ij}^T (R_i^T (t_j - t_i) - t_{ij}) \\ \theta_j - \theta_i - \theta_{ij} \end{bmatrix} \rightarrow \text{vector space}$$

Tentukan turunan parsial  $e_{ij}$  terhadap  $x_i$  dan  $x_j$ ,

$$x_i = \begin{bmatrix} t_i \\ \theta_i \end{bmatrix}; x_j = \begin{bmatrix} t_j \\ \theta_j \end{bmatrix}$$

$$\frac{\partial e_{ij}}{\partial x_i} = \begin{bmatrix} \frac{\partial \Delta t}{\partial t_i} & \frac{\partial \Delta \theta}{\partial \theta_i} \end{bmatrix}, \frac{\partial e_{ij}}{\partial x_j} = \begin{bmatrix} \frac{\partial \Delta t}{\partial t_j} & \frac{\partial \Delta \theta}{\partial \theta_j} \end{bmatrix}$$

$$\frac{\partial e_{ij}}{\partial x_i} = \begin{bmatrix} -R_{ij}^T R_i^T & R_{ij}^T \frac{\partial R_i^T}{\partial \theta_i} (t_j - t_i) \\ 0 & -1 \end{bmatrix}$$

$$\frac{\partial e_{ij}}{\partial x_j} = \begin{bmatrix} R_{ij}^T R_i^T & 0 \\ 0 & 1 \end{bmatrix}$$

Jacobian matriks  $J_{ij}$  hanya berisikan nilai  $\frac{\partial e_{ij}}{\partial x_i}$  pada baris ke- $i$ ,  $\frac{\partial e_{ij}}{\partial x_j}$  pada baris ke- $j$ , dan yang lainnya bernilai 0

$$J_{ij} = \begin{bmatrix} 0 & 0 & 0 & \dots & \frac{\partial e_{ij}}{\partial x_i} & \dots & \frac{\partial e_{ij}}{\partial x_j} & \dots & 0 & 0 & 0 \end{bmatrix}$$

$$\nabla_{ij} = J_{ij}^T \Omega_{ij} e_{ij}$$

$$H_{ij} = J_{ij}^T \Omega_{ij} J_{ij}$$

$$\nabla = \sum_{i,j} J_{ij}^T \Omega_{ij} e_{ij}$$

$$H = \sum_{i,j} J_{ij}^T \Omega_{ij} J_{ij}$$

Setelah  $\nabla$  dan  $H$  dapat diperoleh, permasalahan Non-Linear Least Square dapat diselesaikan dengan iterasi proses optimisasi menggunakan Gauss-Newton atau Levenberg-Marquardt hingga  $\Delta F(x) < \text{tolerance}$ .

$$(\text{GN}) \Delta x = -H^{-1} \nabla$$

$$(\text{LM}) \Delta x = -(H + \lambda \text{diag}(H))^{-1} \nabla$$

$$x \leftarrow x + \Delta x$$

## References :

- [\[SLAM\]\[En\] Errors and Jacobian Derivations for SLAM Part 1](#)
- [A Technical Walkthrough of the SLAM Back-end](#)
- [Graph-based SLAM using Pose Graphs \(Cyrill Stachniss\)](#)